— 포트폴리오 · 2026

Sean Kakhkhorov

Full-Stack Developer (AI & DevOps)

웹 서비스를 처음부터 끝까지 만들고 직접 운영합니다. 크리에이터 마켓플레이스부터 AI 온라인 서점, 출처를 인용하는 비자 정보 베타, AI 서류 검토까지 **운영 중인 서비스 5개**가 있습니다.

약 3년
실무 웹 개발 경력

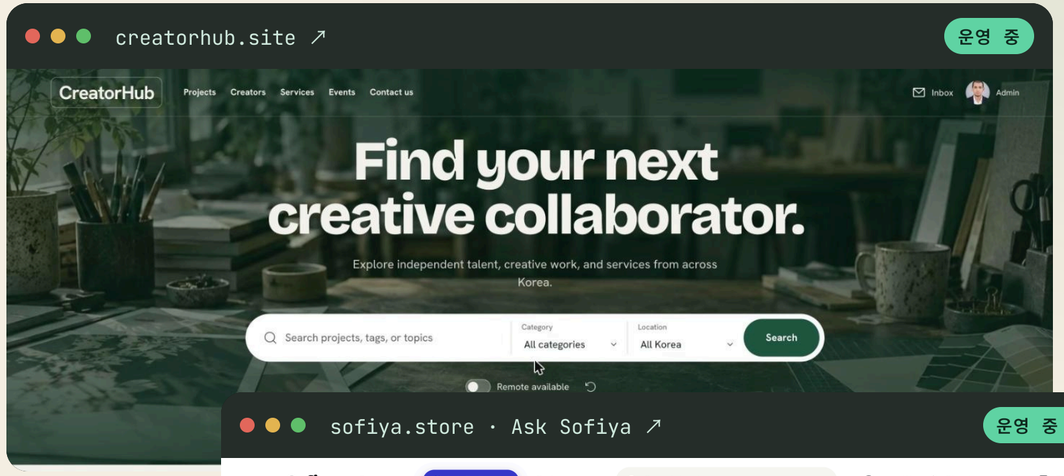
20+
IT Local에서 맡은 고객사

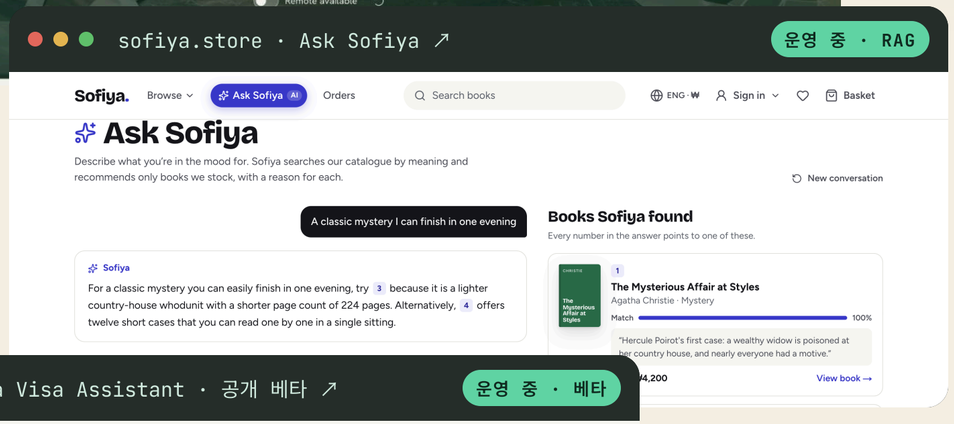
5
개 운영 중인 서비스: 개인 4, 공동 1

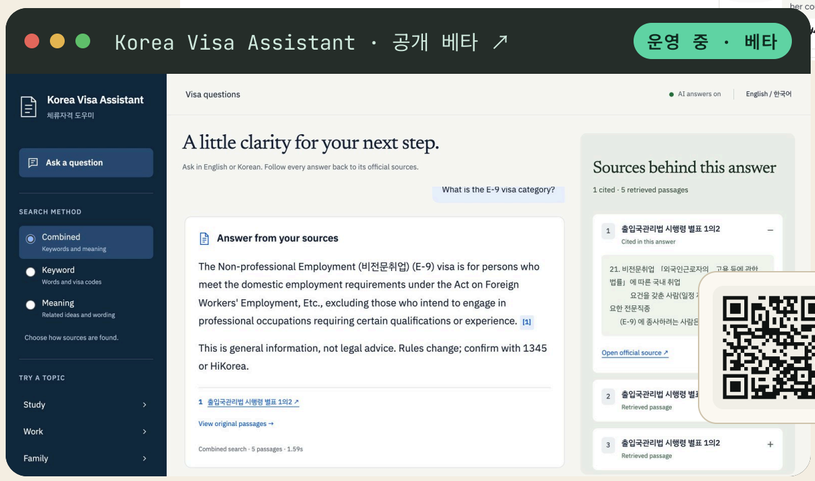
293
건 CreatorHub 자동화 검증 기록

CreatorHub ↗ · Sofiya ↗ · Korea Visa Assistant ↗
CargoCheck AI ↗ · Lexara ↗ · sean-kakhkhorov.site

대한민국 수원 · kakhkhorov97@gmail.com · github.com/kakhkhorov97





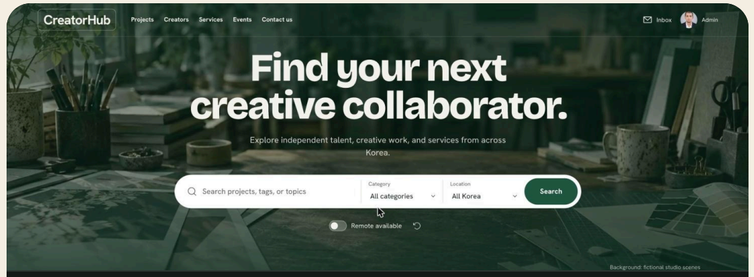


전체 포트폴리오
sean-kakhkhorov.site

— 프로젝트 한눈에 보기

제가 만든 것들.

함께 보기: 자기소개 p. 03 · 경력 p. 04 · 기술 p. 05 · 연락처 p. 22

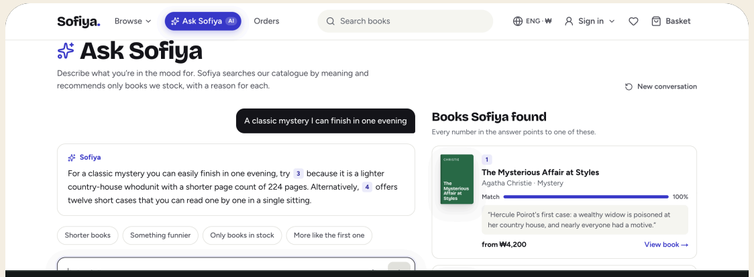


CreatorHub ↗ 운영 중 · 개인

비공개 채팅, 관리자 검수, Gemini 어시스턴트를 갖춘 국내 크리에이터 마켓플레이스.

Next.js · NestJS · GraphQL · MongoDB

실제 앱 열기 ↗ p. 06 →

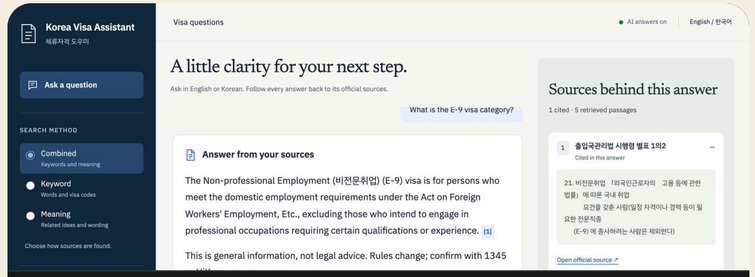


Sofiya ↗ 운영 중 · RAG

AI 온라인 서점: 재고가 있는 책만 출처와 함께 추천하는 RAG 컨시어지 (hit@5 100%).

Next.js · NestJS · pgvector · Gemini

실제 사이트 열기 ↗ p. 12 →

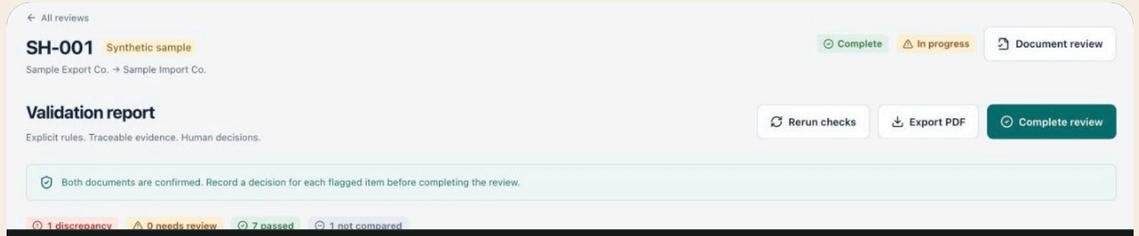


Korea Visa Assistant ↗ 운영 중 · 베타

선별한 한국 공식 비자 자료에 근거해 출처를 인용하는 영·한 답변, 질문 32개에서 하이브리드 검색 hit@5 0.969.

Python · FastAPI · Chroma · Gemini

베타 열기 ↗ p. 15 →

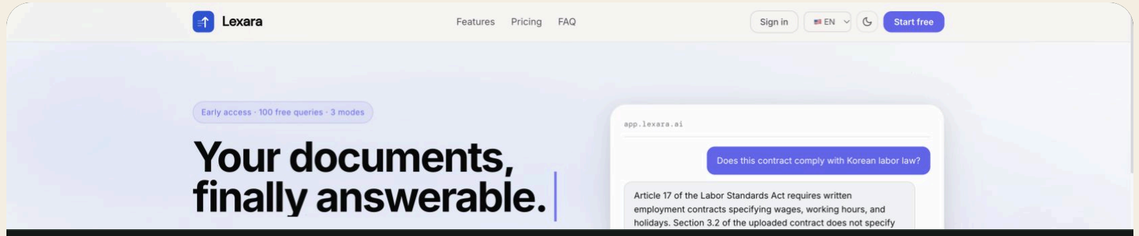


CargoCheck AI ↗ 운영 중 · GEMINI

AI 서류 검토: Gemini 추출, 사람의 확인, 명시적인 규칙 검사.

React · NestJS · Neon · Upstash

실제 앱 열기 ↗ p. 18 →



Lexara ↗ 운영 중 · 공동

출처를 인용하는 문서 질의응답. FastAPI 백엔드 개발에 참여했습니다.

FastAPI · PostgreSQL · React

공개 사이트 열기 ↗ p. 21 →

— 자기소개

코드부터 운영까지, 풀스택 개발.

Golden Valley Investment(구 Atlantis Investment)에서 프로젝트 단위 계약으로 Express·MongoDB 백엔드를 유지보수하는 주니어 백엔드 개발자로 시작했습니다. 이후 2023년 9월부터 2026년 4월까지 IT Local에서 풀타임 풀스택 개발자로 일하며, 핵심 개발자 4인 팀의 일원으로 20개 이상 고객사를 맡았습니다. 데이터베이스 설계와 인증부터 배포, DNS, 장애 대응까지 맡으면서, 코드를 어떻게 작성하느냐뿐 아니라 출시 후 어떻게 동작하느냐까지 신경 쓰게 되었습니다.

그 뒤로 직접 서비스를 출시했습니다. 혼자 개발해 운영 중인 크리에이터 마켓플레이스 **CreatorHub ↗**, RAG 도서 컨시어지를 갖춘 AI 온라인 서점 **Sofiya ↗**, 공식 자료를 인용해 한국 비자 규정을 설명하는 공개 베타 **Korea Visa Assistant ↗**, 운영 중인 AI 서류 검토 앱 **CargoCheck AI ↗**, 다른 개발자와 함께 만든 문서 질의응답 플랫폼 **Lexara ↗**입니다.

Claude Code, Codex 같은 코딩 에이전트를 명문화된 저장소 규칙 안에서 활용합니다. 모든 변경은 제가 직접 승인하고, 병합 전에는 자동 검사를 거칩니다.

안정성
모니터링, 로그 분석, 신속한 장애 대응

보안
인증, 입력값 검증, 코드 리뷰

문서화
API와 배포 절차 문서화

AI 워크플로
검토 단계를 갖춘 코딩 에이전트



카흐호로프 쇼흐자혼 (Sean)
Full-Stack Developer (AI & DevOps)
대한민국 경기도 수원시

— 경력

풀스택 웹 개발자
IT Local · 2023.09 – 2026.04

주니어 백엔드 개발자
Golden Valley Investment (구 Atlantis) · 2023.04 – 2023.09

— 언어

한국어 (학사 전 과정 한국어 수학 · 기술 면접 가능 · 기술 문서 독해 능숙)
영어 (유창) · 우즈베크어 (모국어) · 러시아어 (초급)

— 체류자격

국내 4년제 학사 졸업 · 채용 시 E-7 변경 가능

— 경력 · IT LOCAL · GOLDEN VALLEY

고객사 웹사이트, 개발부터 서버까지

IT Local은 타슈켄트의 B2B 웹 에이전시로, 직원은 약 20명입니다. 핵심 개발자 4인 팀에서 첫 페이지부터 그 페이지가 돌아가는 서버까지 전 과정을 맡았습니다.
고객사 사이트는 IT Local 고객의 자산이므로 싣지 않았습니다.

20개 이상 고객사
건설, 유통, 요식, 기업 및 공공기관

→

핵심 개발자 4인 팀
전체 직원 약 20명

→

배포: 15~20분 → 4~5분
5개 이상 사이트에 쓰인 GitHub Actions 템플릿

→

Ubuntu 서버 5대 → 15대
Nginx, SSL, DNS, PM2, Docker, 백업

— 직접 해결한 문제 세 가지

수동 배포 → CI

문제. 배포를 수작업으로 했습니다. 서버마다 SSH로 접속해 코드를 받고, 설치하고, 재시작하느라 매번 15~20분이 걸렸고, 한 단계만 빠져도 사이트가 멈출 수 있었습니다.

한 일. 담당 고객사 프로젝트에서 이 절차를 GitHub Actions CI/CD로 옮겨, 푸시하면 매번 같은 방식으로 배포되게 했습니다.

결과. 배포 시간이 4~5분으로 줄었고, 팀이 이 파이프라인을 템플릿으로 채택해 5개 이상 사이트에 적용했습니다.

고객사 사이트 장애 대응

문제. 고객사 사이트가 약 15~20분간 중단되었습니다. 서버 메모리가 부족해진 것이 원인이었습니다.

한 일. Nginx, PM2, 애플리케이션 로그를 따라가 업로드가 메모리에 버퍼링되는 것을 찾아냈고, 업로드 크기·동시성 제한과 PM2 자동 재시작을 적용했습니다.

결과. 같은 장애는 다시 발생하지 않았습니다. 이렇게 주요 장애 3~4건을 해결하고, 해결 방법을 팀을 위해 문서로 남겼습니다.

데이터 증가로 느려진 페이지

문제. 카탈로그 데이터가 수만 건으로 늘어나자, 검색할 때마다 컬렉션 전체를 스캔해 약 3~5초가 걸렸습니다.

한 일. 필터와 정렬 순서에 맞는 복합 인덱스를 추가하고, 커서 기반 페이지네이션으로 바꿨습니다.

결과. 검색 시간이 1초 미만으로 줄었고, 데이터가 계속 늘어도 빠르게 유지되었습니다.

IT Local에서 한 그 밖의 일
아파트 분양 관리자 대시보드(역할 기반 접근 제어, 재고 GraphQL API, 관리자 테이블 UI), 코드 리뷰, API·배포 문서화, 퇴사 전 전체 인수인계.

Golden Valley Investment (구 Atlantis) · 2023.04 – 2023.09
주니어 백엔드, 원격 프로젝트 단위 계약: 기존 Express.js / MongoDB 백엔드 유지보수(버그 수정, 소규모 기능, JWT·세션 인증, 업로드, 검색 인덱스).

— 기술 및 도구

기술 스택

핵심 · 매일 사용 사용 경험 있음

프론트엔드

React · Next.js · TypeScript · JavaScript · Apollo Client · Redux Toolkit · MUI · Tailwind CSS · SCSS · HTML · CSS · jQuery · Axios · TanStack Query · React Router · Socket.IO Client · Framer Motion · Three.js · Swiper · Anime.js · Typed.js · TUI Editor · Bootstrap · Chakra UI · shadcn/ui · Figma

백엔드

Node.js · NestJS · Express · GraphQL · REST API · Socket.io · JWT & OAuth · Python · FastAPI · Zod · 역할 기반 접근 제어 · EJS · bcryptjs · Multer

데이터베이스

PostgreSQL (Neon) · pgvector · Drizzle ORM · MongoDB · Mongoose · Redis (Upstash) · 트랜잭션 · 인덱싱·쿼리 최적화 · BullMQ · Chroma · MySQL

DevOps·클라우드

Docker · Google Cloud Run · GitHub Actions · Nginx · Vercel · Render · Cloudflare · Docker Compose · Linux (Ubuntu) · DNS·TLS · PM2 · Git & GitHub

AI·검색

Gemini API · RAG: BM25 + 벡터 (RRF) · 구조화 추출 · OCR (Tesseract, Poppler) · OpenAI API · Kiwi 형태소 분석기 · Chroma · hit@k · recall@k · MRR · Claude Code · Codex · Cursor

테스트 및 도구

Jest · Supertest · Vitest · ESLint · Prettier · pytest · 통합 테스트 · API 계약 테스트 · PostHog · Postman

사용한 곳: CreatorHub(운영 중)의 Next.js, NestJS, GraphQL, MongoDB, Docker, Nginx · CargoCheck AI(운영 중)의 React, NestJS, Gemini, Neon PostgreSQL, Upstash Redis, Vercel, Render · Sofiya(운영 중)의 Next.js, NestJS, pgvector, Drizzle, Gemini, Cloud Run · Korea Visa Assistant(운영 중인 베타)의 Python, FastAPI, Kiwi, BM25, Chroma, Gemini, Cloud Run · Lexara(공동)의 FastAPI, pgvector.

— 주요 프로젝트 · 01 · 운영 중

CreatorHub.

개인 프로젝트 (2026.07 – 현재): 프론트엔드, 백엔드, 인프라를 직접 설계·개발·배포했습니다.

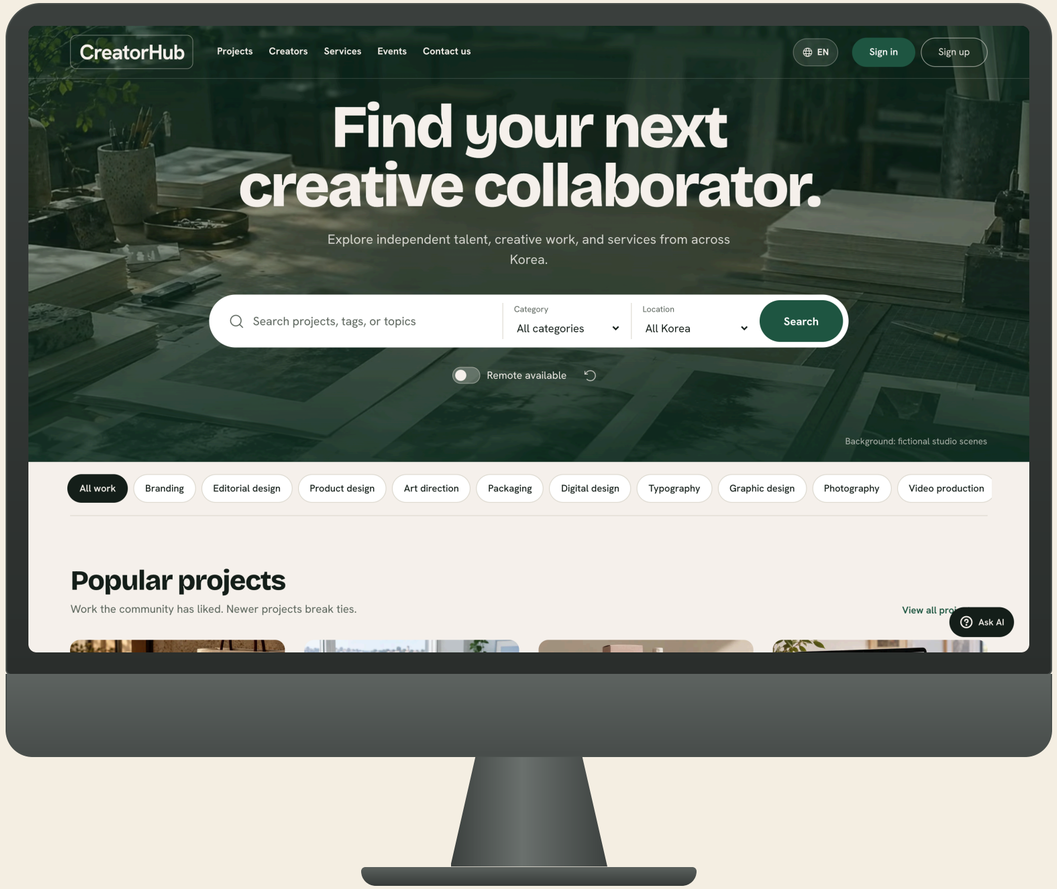
방문자가 한국 각지의 독립 크리에이터를 찾고, 그들의 프로젝트와 서비스를 살펴보며, 비공개 프로젝트 문의를 보낼 수 있는 포트폴리오 탐색 플랫폼입니다.

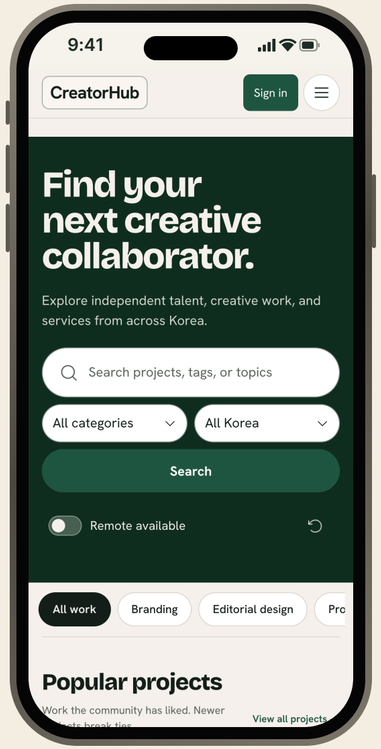
- 카테고리, 지역, 원격 근무로 검색
- 관리자 승인을 거치는 크리에이터 워크스페이스
- 실시간 채팅이 가능한 비공개 문의
- 사이트 콘텐츠로만 답하는 Gemini AI 파인더

프론트엔드	Next.js · React · TypeScript
백엔드	NestJS · GraphQL · Socket.io
데이터	MongoDB · Mongoose
인프라	Docker · Nginx · GitHub Actions
AI	Gemini API

사이트 방문 ↗

저장소: CreatorHub · CreatorHub-next





— CREATORHUB · 사례 연구

한 번 클릭, 하나의 문의: 재시도에 안전한 요청.

문제. 더블 클릭이나 끊긴 연결 때문에 같은 문의나 채팅 메시지가 두 번 전송될 수 있었습니다. 서버는 이를 새 요청 두 개로 보고 둘 다 저장해, 크리에이터에게 알림도 두 번 보낼 수 있었습니다.

1

폼마다 하나의 키

브라우저가 폼마다 키를 하나 만들고, 재시도할 때마다 같은 키를 다시 씁니다

`crypto.randomUUID()`

→

2

먼저 확인

트랜잭션 안에서, 이미 알려진 키라면 저장된 레코드를 그대로 돌려줍니다

`findOne(clientId, key)`

→

3

최후 방어선인 인덱스

두 요청이 동시에 오면 유니크 인덱스가 두 번째 삽입을 거부합니다

`partial unique index`

→

✓

하나의 레코드

밀린 요청은 첫 번째 레코드로 응답하므로 사용자는 결과를 하나만 봅니다

`uq_inquiry_request`

같은 키, 다른 내용

같은 메시지 키를 다른 내용으로 다시 쓰면, 기존 메시지를 조용히 유지하는 대신 충돌 오류를 돌려줍니다.

모든 변경에 버전

모든 상태 변경은 기준이 된 버전을 함께 보내므로, 오래된 화면이 더 새로운 상태를 덮어쓸 수 없습니다.

검증

통합 테스트에서 같은 문의를 두 번 제출하고 같은 키로 메시지를 동시에 보냅니다. 결과는 정확히 이벤트 1건, 메시지 1건, 알림 1건입니다.

재시작에도 안전한 알림 워커

작업은 60초 임대로 가져가고 팔로워 100명 배치마다 커서를 저장합니다. 워커가 멈추면 다음 실행이 커서부터 이어 가며, 알림은 팔로워와 이벤트 조합마다 하나만 생깁니다.

비용이 폭증하지 않는 AI 파인더

같은 사이트 요청만 허용하고, 방문자당 분당 8개 메시지, 일일 상한, 3.5초 안에 끝나는 검색, 대체 모델로 한 번 재시도를 적용했습니다. Gemini 키는 서버에만 있습니다.

좋아요, 저장, 팔로우, 댓글 재시도에도 같은 패턴을 적용했습니다.

— CREATORHUB · 사례 연구

테스트, CI/CD, 롤백.

두 저장소 모두 푸시할 때마다 테스트합니다. 배포는 수동으로 시작하는 별도 워크플로를 거칩니다.

— 테스트 범위

백엔드 단위 · Jest
비즈니스 규칙: 문의 상태, 비밀번호, 요청 제한

API 통합 · Jest
일회용 MongoDB 레플리카 셋에서 실제 GraphQL 요청

프론트엔드 · Node.js
세션, 로그인, AI 채팅 라우트, 번역

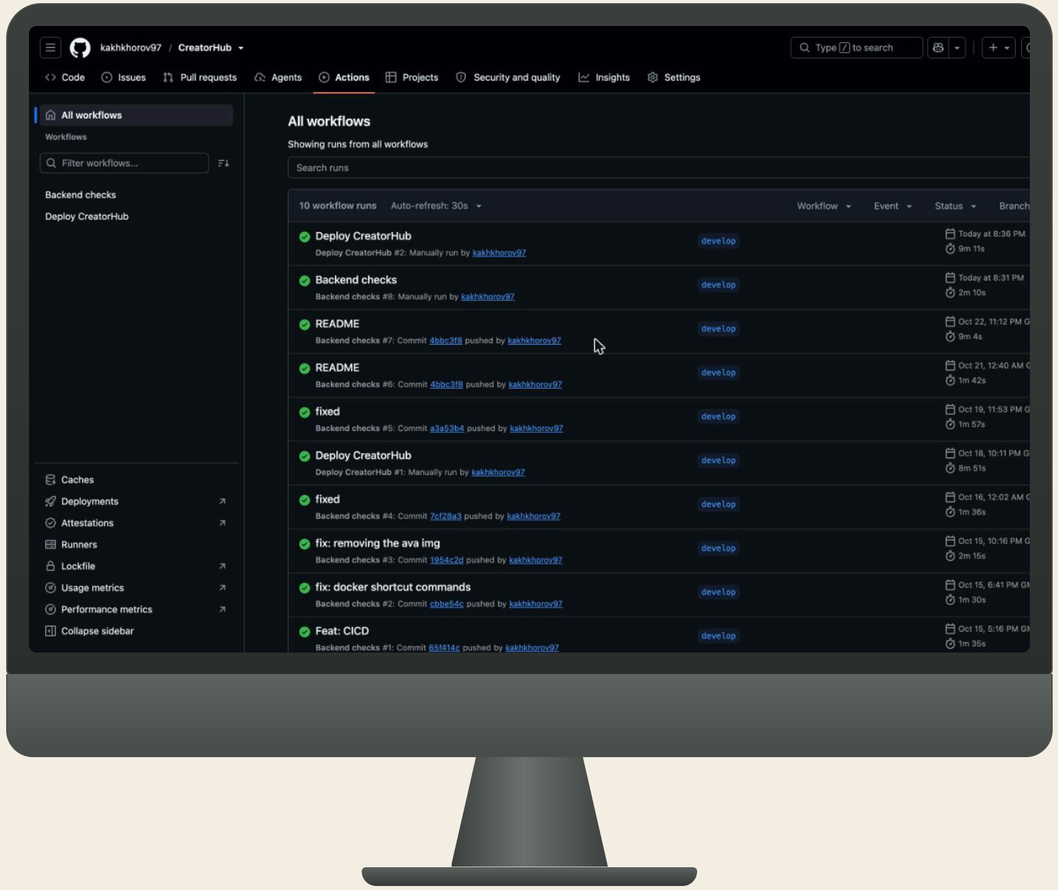
정적 검사
TypeScript, ESLint, 모든 쿼리를 스키마와 대조

```
recorded locally · 17 Oct 2026

$ backend   jest           ✓ 162/162 tests · 16 suites
$ backend   deploy scripts ✓ 23/23
$ frontend  node --test    ✓ 108/108
$ both      typecheck · lint · contract (119 ops) ✓ passed
= 293 automated checks recorded (162 + 23 + 108)
```

— 배포 과정

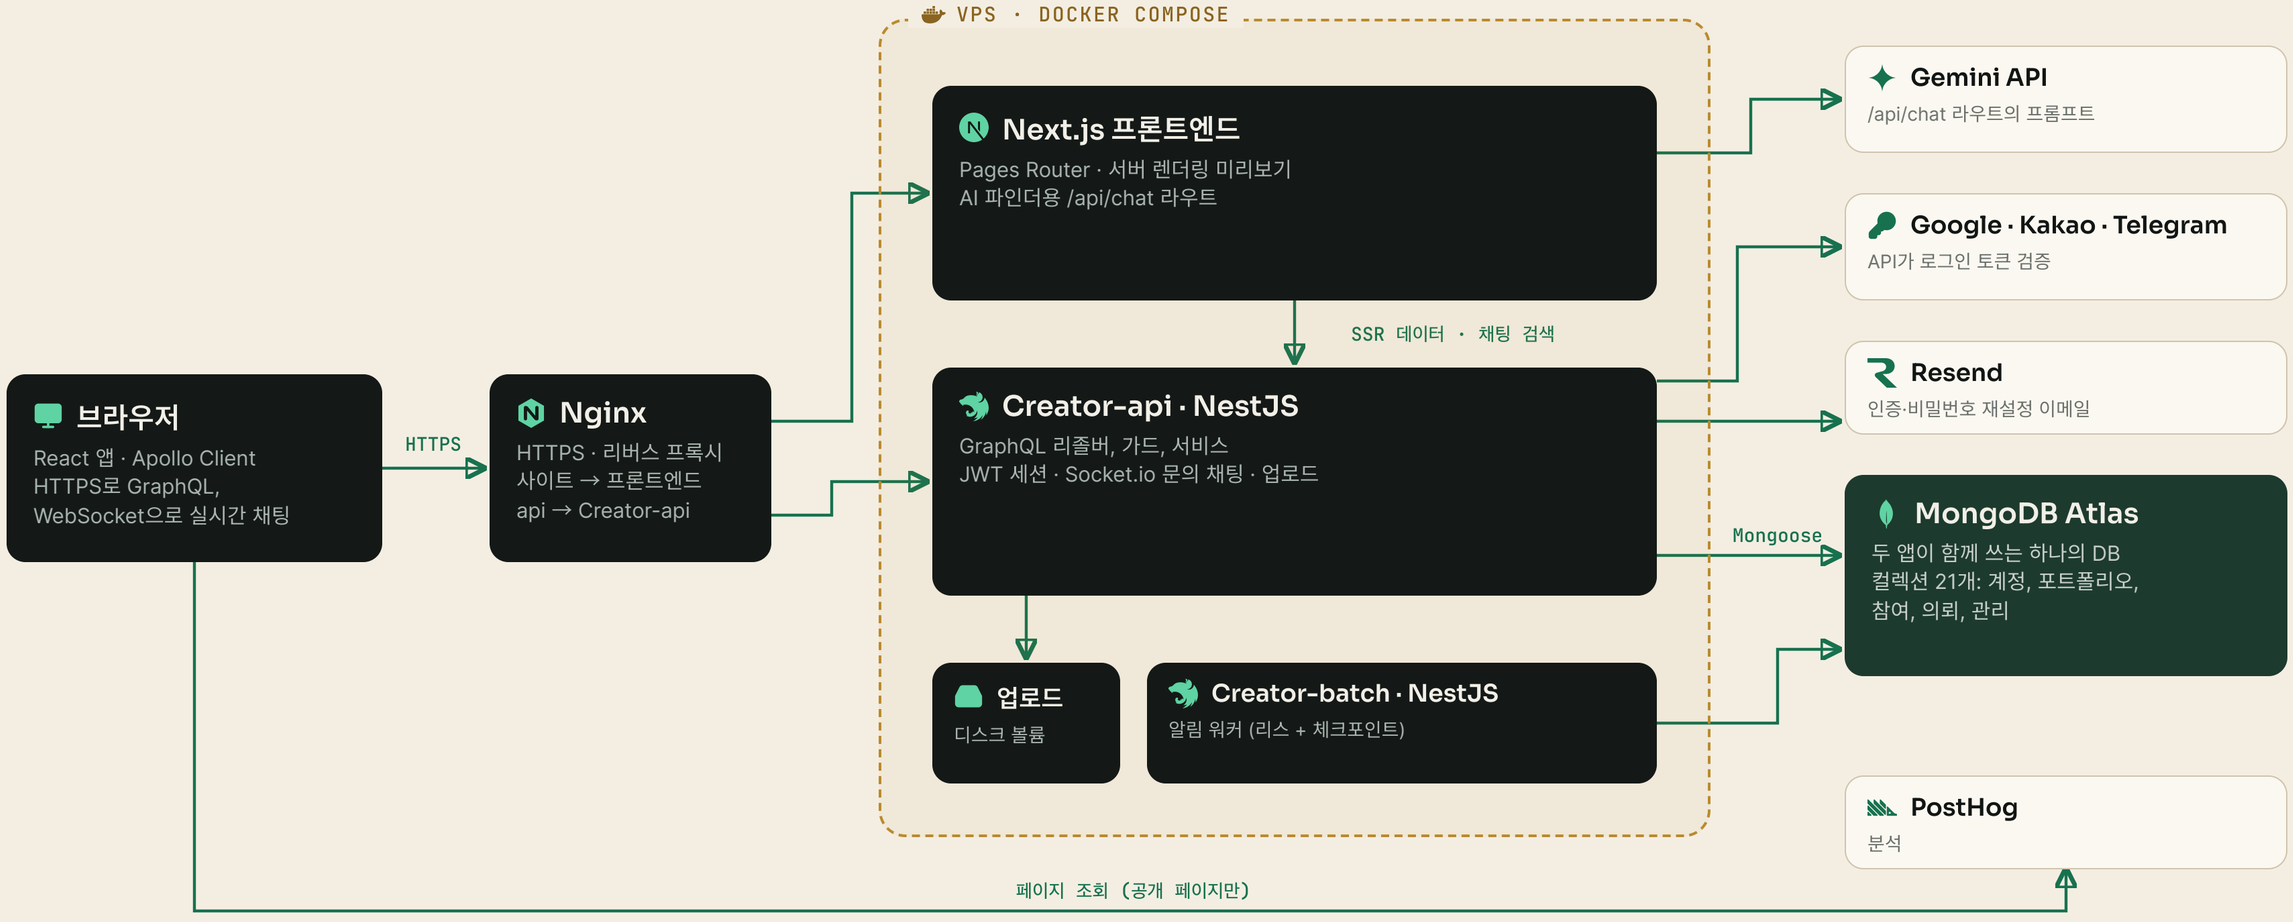
1. **develop·main에 푸시할 때마다** 설치, 타입 검사, 린트, 테스트, 빌드를 실행합니다.
2. **배포 워크플로**는 수동으로 시작하며, 백엔드·프론트엔드 커밋 한 쌍에 대해 모든 검사를 다시 실행합니다.
3. **제한된 SSH**로 “deploy”와 커밋 ID 두 개만 받는 배포 전용 계정에 접속합니다.
4. **헬스 체크 후 전환:** 새 이미지는 설정된 최대 180초 안에 정상 상태를 보고해야 하며, 실패하면 이전 이미지로 자동 복원됩니다.



화면: 2026년 10월 24일 GitHub Actions, 수동 Deploy CreatorHub 실행 2회를 포함해 10회 모두 통과. 180초는 설정값이며 측정된 복구 시간이 아닙니다. 데이터베이스 변경은 롤백하지 않습니다.

— CREATORHUB · 아키텍처

세 개의 애플리케이션, 하나의 데이터 모델



— CREATORHUB · 데이터 모델

데이터 설계 방식.

API와 워커가 함께 쓰는 하나의 MongoDB 데이터베이스에 21개 컬렉션이 있습니다. 참조는 서비스에서 검사하고, 반드시 지켜야 하는 규칙은 유니크 인덱스로 강제합니다.

계정

`users` `authIdentities` `authSessions` `authTokens`

- 로그인 방식마다 별도 레코드라, 한 사람이 이메일·Google·Kakao를 함께 사용 가능
- 리프레시·이메일 토큰은 해시로만 저장되고 자동 만료
- 세션이 레코드로 저장되어, 사용자 정지 시 모든 세션 종료

포트폴리오

`creatorProfiles` `categories` `portfolioProjects` `services`

- 프로필과 크리에이터별 프로젝트에 읽기 쉬운 고유 슬러그
- 소셜 링크와 프로젝트 미디어는 항상 상위 문서와 함께 읽으므로 임베드
- 인덱스는 공개 피드에 맞춰 상태, 최신순으로 구성

참여

`creatorFollows` `projectLikes` `savedProjects` `projectComments` `activityEvents`

- 좋아요·저장·팔로우는 사람·항목당 하나로, 유니크 인덱스로 강제
- 언팔로우는 삭제하지 않고 팔로우를 비활성화
- 활동 이벤트에 워커의 리스와 커서를 저장해 안전하게 전달

문의

`inquiries` `inquiryMessages` `inquiryEvents` `serviceFeedback`

- 서비스 조건은 임베드된 스냅샷으로 문의에 복사
- 재시도 키와 부분 유니크 인덱스로 문의·메시지 중복 방지
- 모든 상태 변경은 번호가 매겨진 이벤트이며, 완료된 문의당 리뷰는 하나

관리

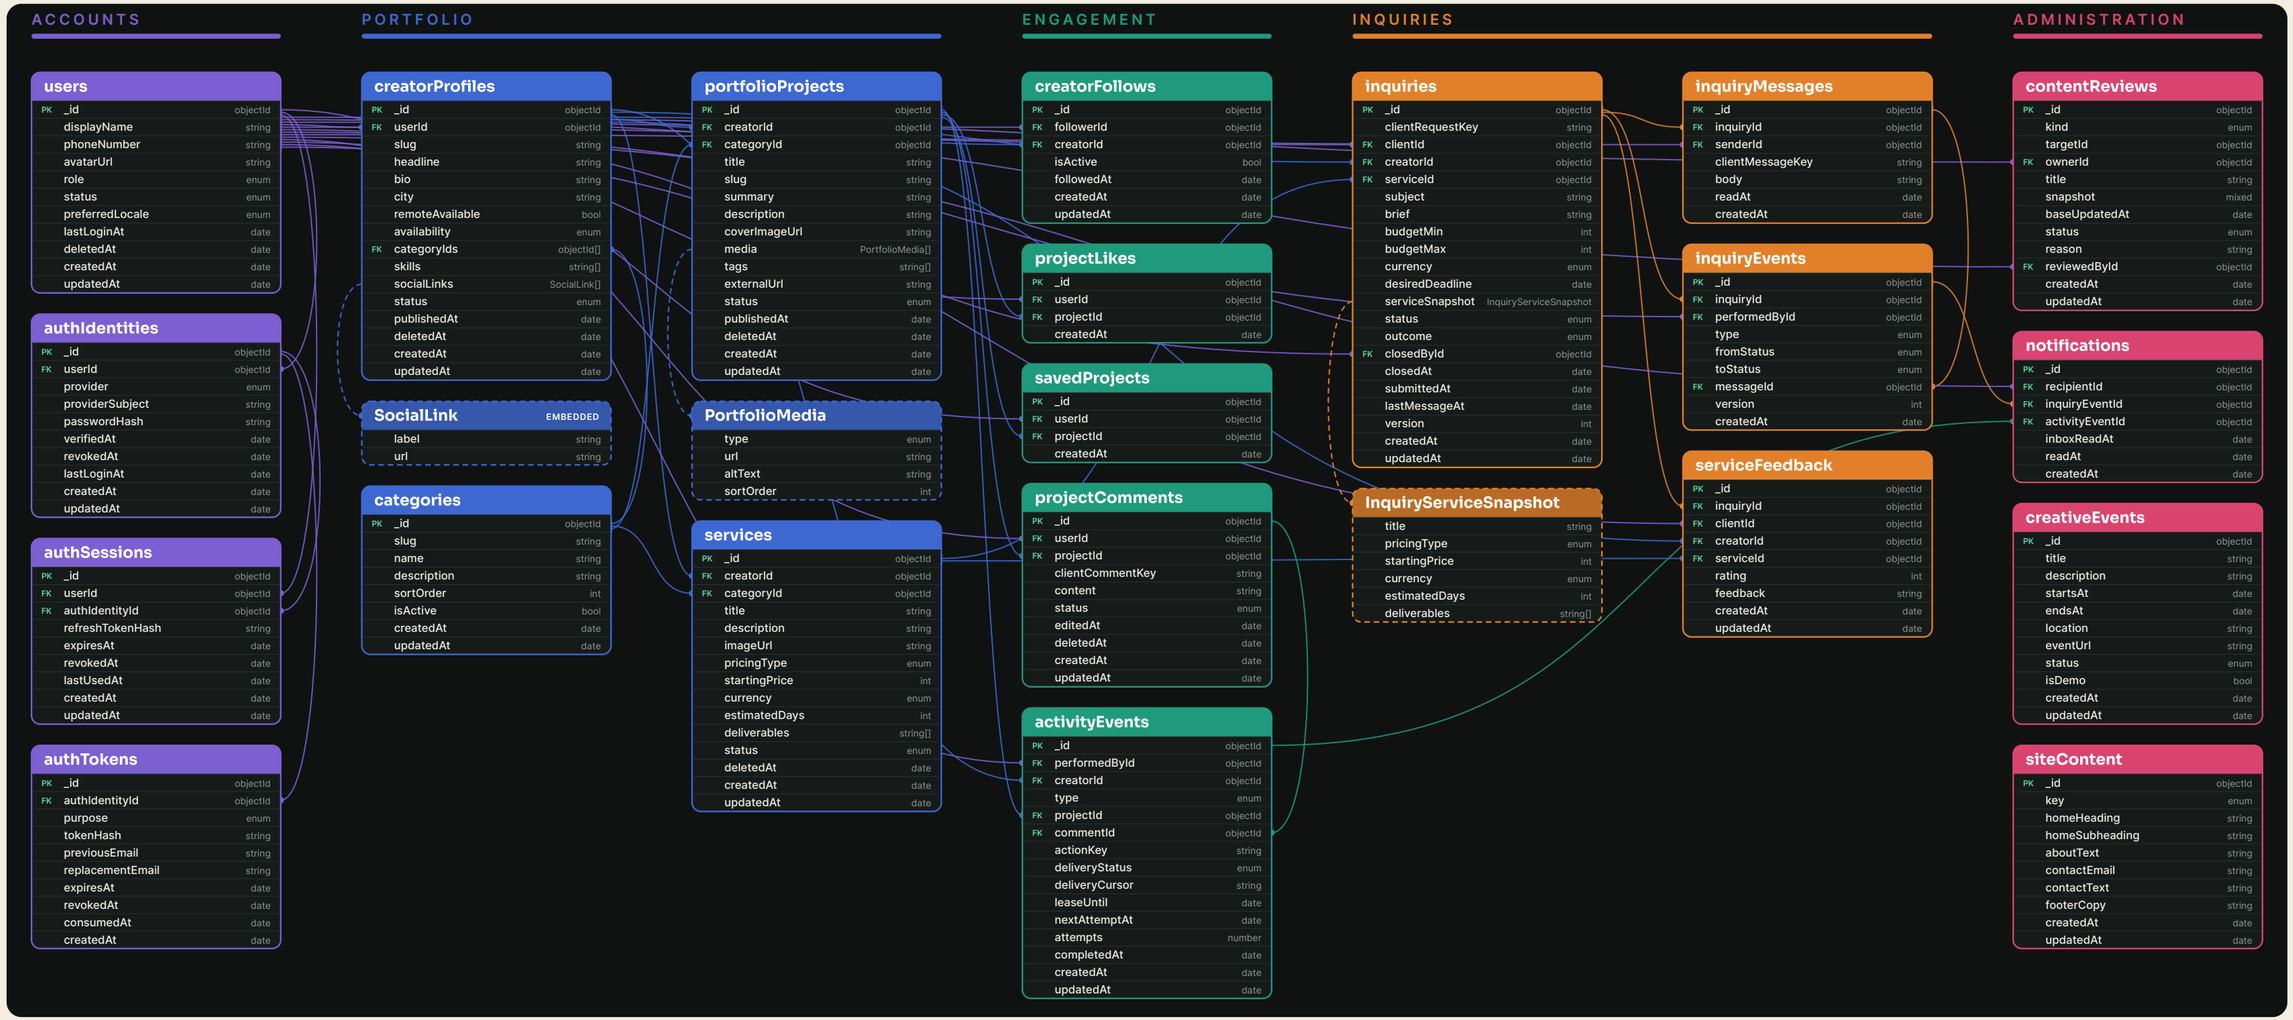
`contentReviews` `notifications` `creativeEvents` `siteContent`

- 프로필·프로젝트·서비스당 검토 대기는 최대 하나
- 알림은 수신자·이벤트마다 하나
- 사이트 문구는 키가 있는 문서 하나라 수정 시 재배포 불필요

다음 페이지에서 모든 컬렉션, 필드, 참조를 담은 전체 모델을 볼 수 있습니다.

— CREATORHUB · ER 모델 · 전체 컬렉션

한 페이지로 보는 전체 데이터 모델.



컬렉션 21개 + 임베디드 스키마 3개 · 필드 233개 · 참조 40개 · 실선 = 참조, 점선 = 임베디드 · 확대하면 모든 필드를 읽을 수 있습니다

— 주요 프로젝트 · 02 · 운영 중

Sofiya.

sofiya.store에서 운영 중입니다. 포트폴리오 프로젝트로, 실제 퍼블릭 도메인·자유 라이선스 도서를 다루지만 가격, 재고, 주문은 데모 데이터이며 결제는 Toss 테스트 모드로 실제 배송은 없습니다.

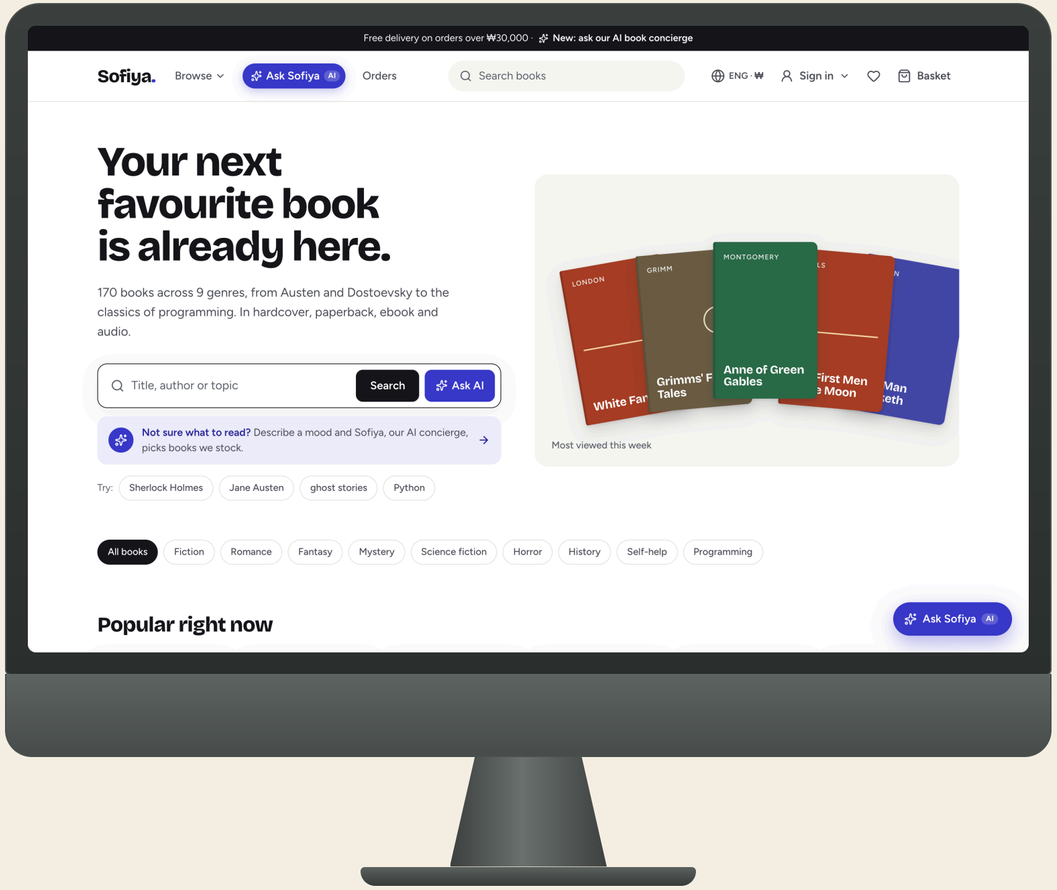
독자가 책을 둘러보고 구매하거나, 원하는 책을 평범한 말로 설명하면 AI 컨시어지 Ask Sofiya가 재고가 있는 책만 출처와 함께 추천하는 온라인 서점입니다.

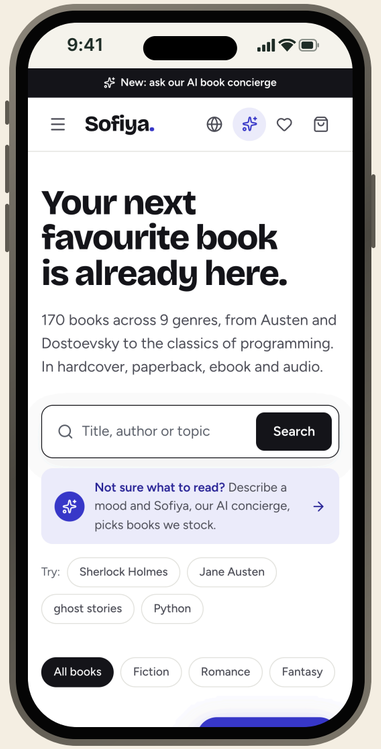
- 약 170권을 장르, 형태, 가격으로 탐색·검색·필터링
- Ask Sofiya: 번호 출처가 붙은 스트리밍 답변
- 영어, 한국어, 러시아어 · 원화와 미국 달러
- Toss 결제(테스트 모드), 회원 계정, Google 로그인, AI 초안 작성 기능이 있는 관리자

프론트엔드	Next.js 15 · React 19 · Tailwind CSS
백엔드	NestJS 11 · Drizzle ORM · Zod
데이터 · AI	PostgreSQL (Neon) · pgvector · Gemini API
인프라	Google Cloud Run · Docker · GitHub Actions

sofiya.store 열기 ↗

저장소: Sofiya-Bookstore (v2)





— SOFIYA · ASK SOFIYA

재고가 있는 책만 추천하는 도서 컨시어지.

1 임베딩
각 책의 제목, 저자, 장르, 설명을 벡터로 변환
`gemini-embedding-001 · 768-d · HNSW`

→

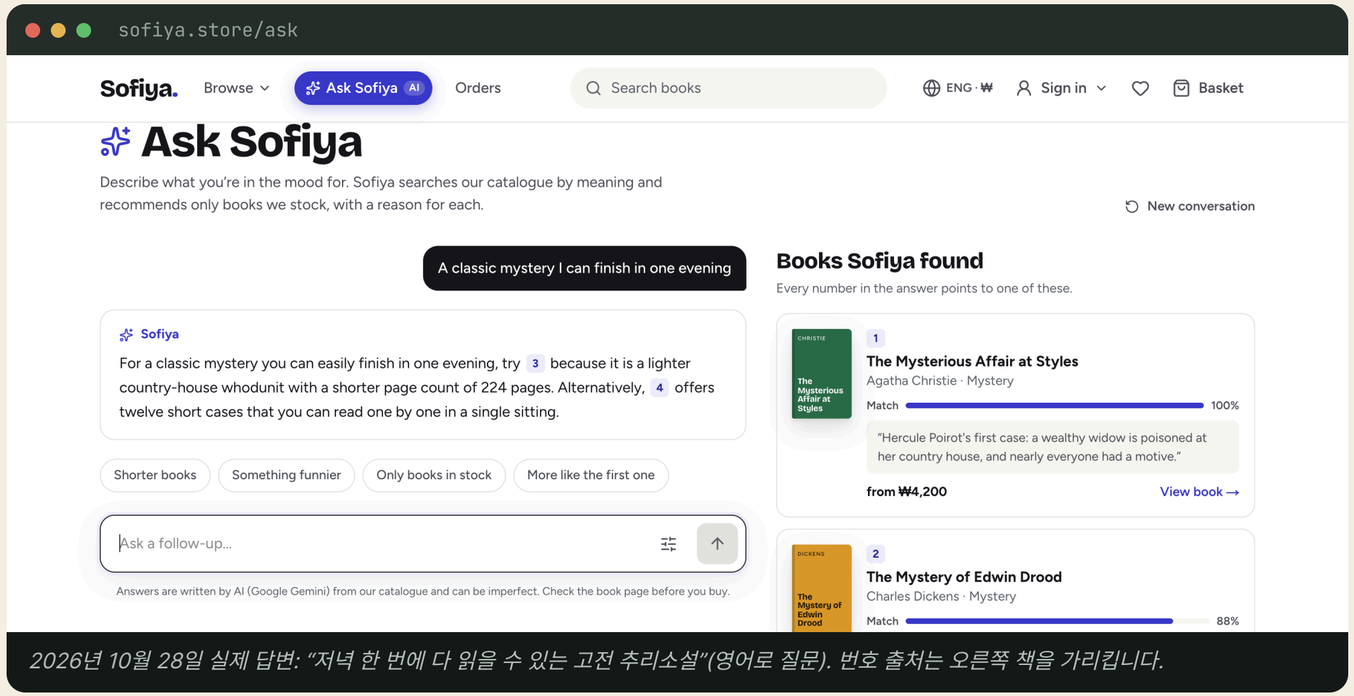
2 두 가지 검색
pgvector 벡터 유사도와 Postgres 전문 검색, 주제에서 벗어난 질문은 0.60 기준 아래로 제외
`pgvector + full-text`

→

3 결합
Reciprocal Rank Fusion으로 두 순위를 합쳐 상위 5권을 모델에 전달
`RRF · top 5`

→

✓ 답변과 검증
Gemini가 답변을 스트리밍하고, 서버는 5권에 없는 출처를 모두 제거
실패 시 대체 모델



2026년 10월 28일 실제 답변: "저녁 한 번에 다 읽을 수 있는 고전 추리소설"(영어로 질문). 번호 출처는 오른쪽 책을 가리킵니다.

— 측정한 검색 성능 · 고정 질문 45개

	hit@1	hit@5	MRR
하이브리드 (사이트)	93%	100%	0.95
키워드만	75%	85%	0.79
의미만	100%	100%	1.00

답할 수 있는 질문 40개(직접, 바꿔 말하기, 주제)와 답할 수 없는 질문 5개로 구성되며, 답할 수 없는 질문은 모두 책을 반환하지 않았습니다. 카탈로그를 보면서 직접 작성한 질문이라 점수가 낙관적이므로 회귀 확인용으로 씁니다. Gemini가 느리거나 멈춰도 키워드 검색이 동작하도록 하이브리드를 유지합니다.

— SOFIYA · 엔지니어링

결제, 보안, 배포.

주문 저장
재고 예약, 멱등성 키로 중복 주문 방지

→

Toss 결제창
카드, 토스페이, 카카오페이, 네이버페이 (테스트 모드)

→

서버 확인
브라우저가 보낸 금액이 아니라 서버에 저장한 금액으로 Toss에 승인 요청

→

결제 완료 또는 만료
미결제 주문은 만료되고 재고가 복구됨

→

취소 = 환불
결제된 주문을 취소하면 자동 환불

보안

state와 PKCE를 적용한 Google OAuth, 해시로 저장한 일회용 이메일·재설정 토큰, 비밀번호 변경 시 세션 종료, 방문자별 요청 제한, HSTS·frame-ancestors 헤더, EXIF/GPS를 제거하는 WebP 재인코딩.

복원력

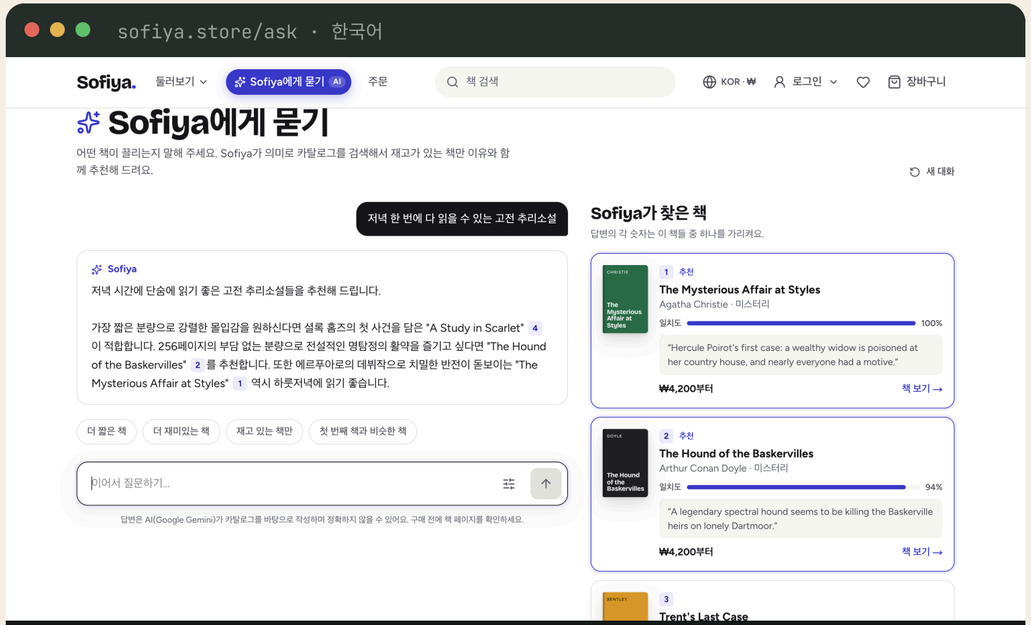
모델이 느리거나 실패하면 두 번째 Gemini 모델로 전환하고, 둘 다 실패해도 일치하는 책은 표시합니다. Redis가 멈추면 요청 제한은 메모리로 전환되고, 이메일은 백그라운드로 발송합니다.

배포

서울 리전 Google Cloud Run의 웹·API 분리 서비스, Secret Manager와 Artifact Registry, Workload Identity Federation을 쓰는 키 없는 GitHub Actions 배포, 새 API가 트래픽을 받기 전 마이그레이션 실행.

테스트

자동화 테스트 약 260개: API 단위 약 120개, 실제 Postgres 대상 API E2E 약 115개(Jest + Supertest), 프론트엔드·공유 코드 약 30개 (Vitest).



같은 질문을 한국어로 했을 때 화면과 AI 답변이 모두 한국어로 바뀝니다. 테스트 모드 결제이며 실제 돈은 청구되지 않습니다.

— 주요 프로젝트 · 03 · 운영 중인 베타

Korea Visa Assistant.

Google Cloud Run에서 운영 중인 공개 베타입니다. 선별한 공식 자료에 근거한 일반 정보이며, 자격을 판단하거나 법률 자문을 하지 않습니다.

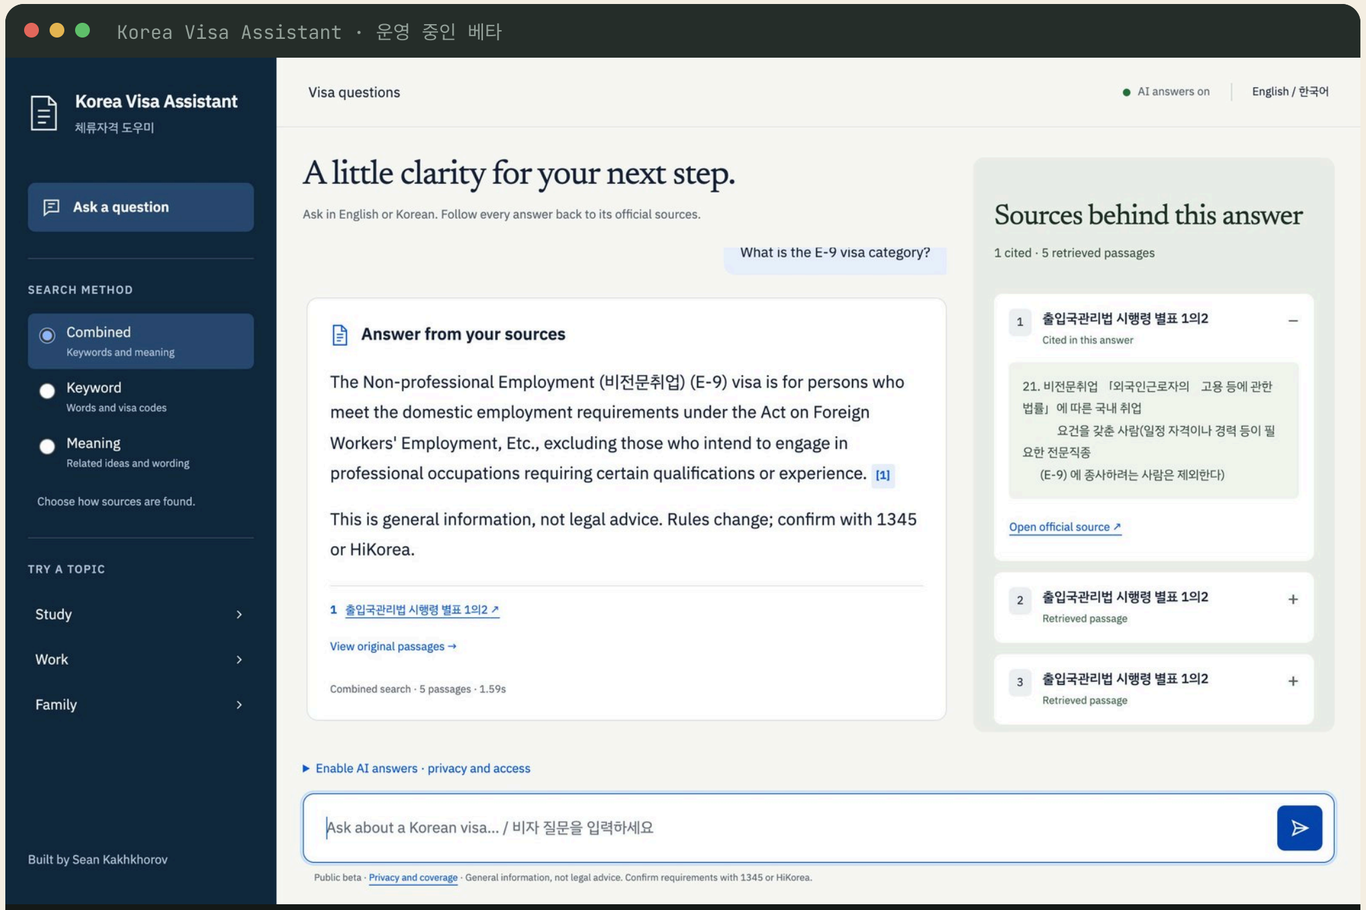
선별한 한국 공식 비자 자료를 검색하고, 출처에 근거한 설명을 영어나 한국어로 받습니다. 키워드 검색은 기본으로 무료이며, AI 답변은 만 18세 이상·대한민국 이용·개인정보 안내에 동의해야 사용할 수 있습니다.

- 키워드, 의미, 결합 검색
- Gemini 답변 문장을 원문 인용과 대조해 확인
- 인용을 누르면 공식 원문이 열림
- 답할 수 없으면 답변을 보류하거나 원문을 표시

백엔드	Python · FastAPI · Pydantic
검색	Kiwi · BM25 · Chroma
AI	Gemini API
인프라	Cloud Run · Cloud Storage · Docker
테스트	pytest · GitHub Actions

실제 앱 열기 ↗

저장소: korea-visa-rag



2026년 10월 28일 운영 앱: 결합 검색으로 받은 영어 답변이 출입국관리법 시행령 별표 1의2를 인용하고, 근거 패널에 그 원문이 열려 있습니다. 개인정보 없는 일반 질문입니다.

공개 자료: 21개 주요 체류자격을 다루는 선별 법령 청크 44개이며, 전체 출입국 데이터베이스가 아닙니다. 하이코리아 안내 발췌본은 저장소에만 있고 운영 자료에는 포함되지 않습니다.

— KOREA VISA ASSISTANT · 사례 연구

한국어 법령에 맞춘 검색.

문제. 한국 법령은 조 › 항 › 호로 구성되고, 질문에는 D-10이나 E-7-1 같은 정확한 코드가 쓰입니다. 고정 길이 청크와 일반 토크나이저는 둘 다 쪼개 버려 맞는 조문을 놓칩니다.

1
조문 단위 분할
법령은 제N조·제N조의M 단위로 나누고 항·호는 함께 유지, 안내 자료는 섹션별로 나눈 뒤 윈도 분할

조문 표시 + 출처 URL

→

2
토큰화
Kiwi 형태소 분석, 비자 코드는 하나의 토큰으로 유지해 코드 검색이 정확히 일치

D-10 · E-7-1

→

3
두 가지 검색
정확한 용어와 코드는 BM25, 의미는 Gemini 임베딩을 쓰는 Chroma

gemini-embedding-001

→

✓
결합
Reciprocal Rank Fusion으로 두 순위를 합쳐 상위 5개 선정

RRF · k = 60

코드를 쪼개지 않는 이유
"E-7-1"을 쪼개면 E-7과 다른 코드까지 모두 일치합니다. 하나의 토큰으로 두면 코드 검색이 정확해집니다.

하이브리드를 쓰는 이유
키워드는 코드를, 의미 검색은 바꿔 말한 표현을 찾습니다. 라벨링한 질문 32개에서 결합으로 MRR이 0.702(BM25), 0.827(벡터)에서 0.935로 올랐습니다.

모든 주장은 원문 구절로 이어집니다
Gemini가 인용문과 함께 주장을 반환하면, 앱이 각 인용문을 원문과 대조하고 확인된 주장에만 출처를 답니다. 근거가 없으면 답변을 보류하고, 확인에 실패하면 원문 구절을 보여 줍니다.

Python · FastAPI · Pydantic · Uvicorn · kiwipiepy · rank-bm25 · Chroma · google-genai · python-telegram-bot

— KOREA VISA ASSISTANT · 테스트와 한계

측정한 것과 측정하지 않은 것.

— 저장된 검색 평가 · 2026년 10월 26일 · 라벨링한 질문 32개

	hit@5	recall@5	MRR
BM25	0.812	0.703	0.702
벡터	0.969	0.891	0.827
하이브리드 (RRF)	0.969	0.891	0.935

청크 44개 자료에 대해 출처를 라벨링한 가상 질문이며, 독립적으로 주석하지 않았습니다. 검색 성능이지 법률 답변 정확도가 아닙니다. 질문 36개 AI 실행(응답 29, 실패 7, 보류 10)은 현재의 원문 대체 방식 이전 결과이며 다시 실행하지 않았습니다.

2d29f46에서 확인, 2026년 10월 28일	결과
Python 테스트 (pytest)	125 / 125 통과
JavaScript 헬퍼 테스트 (node:test)	5 / 5 통과
운영 /api/health	청크 44개 · 모드 3개
운영 AI 질문 8개	인용 3 · 보류 1 · 원문 표시 3 · 거부 1

JavaScript 테스트는 렌더링·탐색 헬퍼만 다루며 브라우저 테스트가 아닙니다. 운영 질문 결과는 이번 캡처에서 관찰한 것이지 측정값이 아닙니다.

— 알려진 한계 · 다음 단계

답변 근거
인용이 일치해도 답변이 그로부터 도출된다는 증명은 아닙니다. 다음: 검토한 문장 단위 테스트 세트.

독립된 질문
이전 대화는 전송되지 않아 질문마다 따로 처리됩니다.

요청 복구
시간 제한, 취소, 재시도가 없고, 의미 검색이 실패해도 키워드 검색으로 전환하지 않습니다.

다루는 범위
전체 서류 목록, 여러 세부 자격, 유학생 취업 규정, 개인별 자격은 다루지 않습니다.

자료 날짜와 이름
수집 날짜는 저장되지만 표시되지 않고, 별표 원문들은 같은 제목과 링크를 씁니다.

한국어 화면
원문 대체 안내와 여러 메시지가 아직 영어입니다.

텔레그램 어댑터
웹의 개인정보 식별자·동의·사용량 검사가 없고, 오류 시 질문 원문을 로그에 남깁니다.

— 베타 운영 방식

스냅샷
Cloud Storage의 고정 인덱스 스냅샷을 SHA-256으로 검증하며, 시작 시 임베딩을 호출하지 않습니다.

공유 사용 제한
요청·일일 AI·동시 실행 제한을 모든 인스턴스가 공유하는 Cloud Storage 기록 하나로 관리합니다.

개인정보
이메일, 전화번호, 여권·외국인등록번호는 AI 호출 전에 거부합니다.

릴리스
Workload Identity Federation을 통한 수동 GitHub Actions 배포, 롤백과 스모크 테스트 포함.

— 주요 프로젝트 · 04 · 운영 중

CargoCheck AI

운영 중이며 실제 서비스에서 Gemini 추출을 사용합니다. 초기 버전으로, 통관 인증이나 자동 승인은 하지 않습니다.

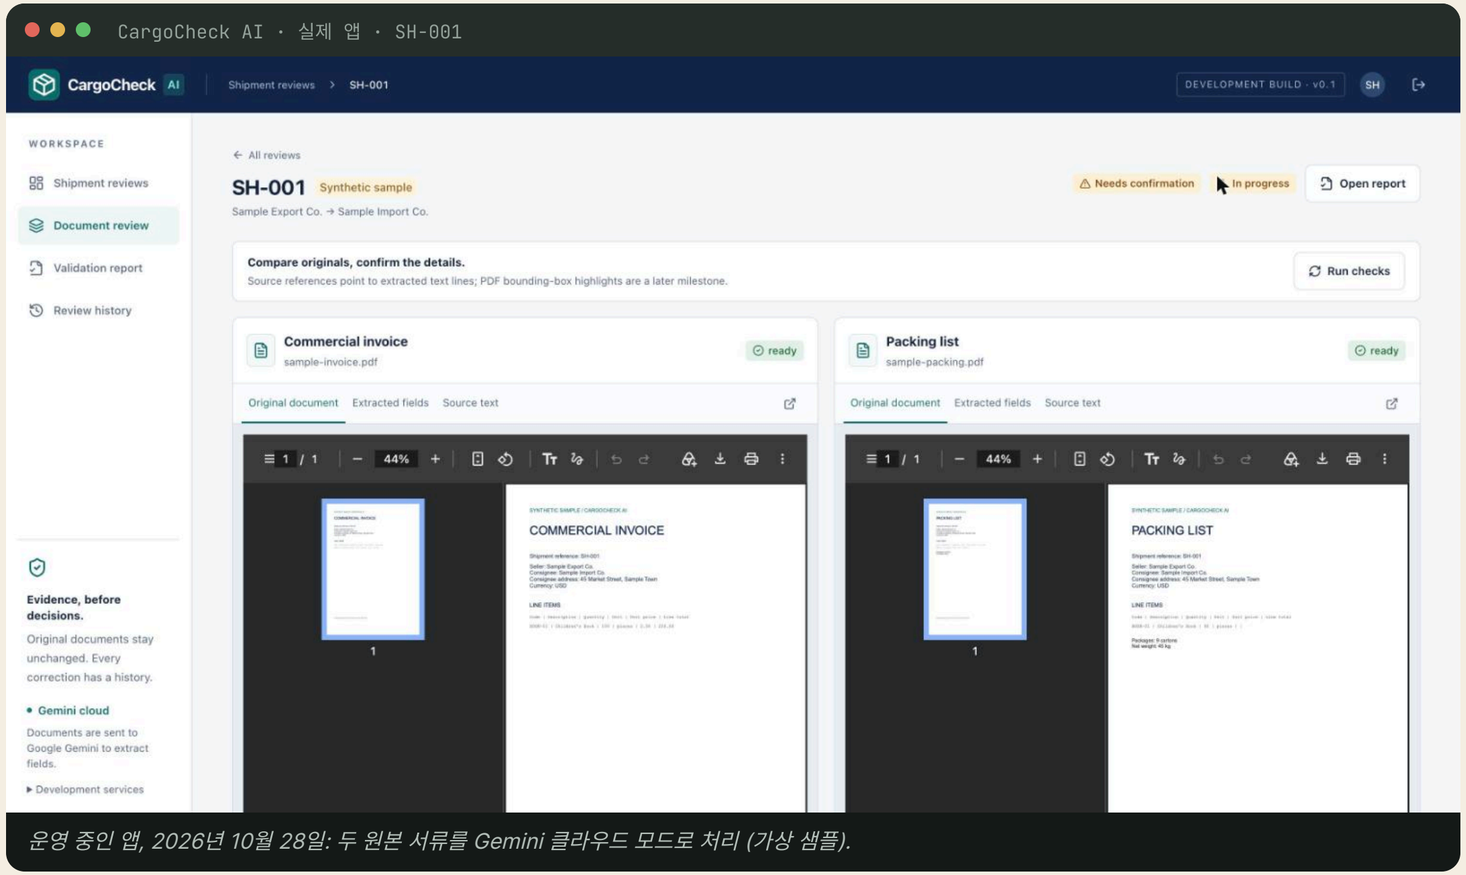
송장과 포장명세서 검토 앱입니다. Gemini가 필드를 추출하고, 검토자가 각 값을 확인하며, 규칙이 불일치를 표시하고, 모든 판단이 기록됩니다. 무역학 전공에서 이런 서류를 검토하는 방법을 배웠고, CargoCheck AI는 그 과정을 소프트웨어로 만든 것입니다.

- 두 서류를 업로드하면 백그라운드 작업에서 Gemini가 필드를 추출
- 규칙 검사, 표시된 항목마다 판단 하나, 이력과 PDF 보고서

프론트엔드	React · TypeScript · Vite
백엔드	NestJS · Zod · decimal.js
AI	Gemini API · Tesseract · Poppler
데이터	Neon · Upstash · BullMQ
인프라	Vercel · Render · Docker

실제 앱 열기 ↗

저장소: cargocheck-ai



운영 중인 앱, 2026년 10월 28일: 두 원본 서류를 Gemini 클라우드 모드로 처리 (가상 샘플).

숨기지 않고 밝히는 알려진 문제: 추출된 원문 줄 번호가 어긋날 수 있고, 일괄 확인이 저장하지 않은 수정을 건너뛸 수 있으며, 업로드 파일이 컨테이너 디스크에 저장되고, 비밀번호 찾기가 아직 없고, CI는 Node 테스트만 실행하며, 모바일 화면에서 Gemini 고지가 가려집니다.

— CARGOCHECK AI · 추출

업로드부터 검토 가능한 필드까지.

문제. 검토자는 송장과 포장명세서 값을 손으로 다시 입력하고 대조합니다. 모델은 값을 잘못 읽을 수 있으므로, 사람이 원본과 대조해 확인하기 전까지 추출한 값은 인정되지 않습니다.

1 업로드
송장과 포장명세서, 파일 시그니처 확인, 원본은 수정하지 않음
`PDF · JPG · PNG · 10 MB`

→

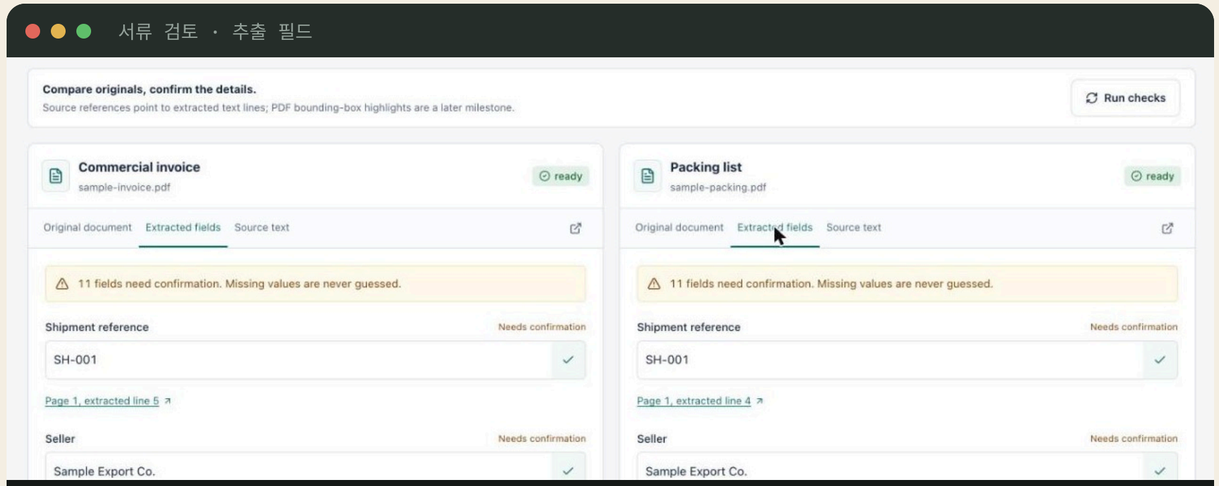
2 추출
BullMQ 작업이 두 서류를 Gemini 구조화 출력으로 전송
`gemini-3.5-flash-lite`

→

3 검증
응답을 Zod 스키마로 파싱하고, 알 수 없는 값은 비워 둠
`없는 값은 null 유지`

→

✓ 확인
검토자가 각 값을 확인하거나 수정하고, 원래 값은 보존
`needs confirmation → confirmed`



2026년 10월 28일 실제 실행: Gemini가 서류마다 필드 11개를 추출했고, 모두 확인을 기다립니다.

추측하지 않음

모델이 찾지 못한 값은 비워 둡니다. 화면에도 '없는 값은 추측하지 않는다'고 표시됩니다.

두 가지 모드

실제 서비스는 Gemini를 사용합니다. 로컬 모드는 AI 키 없이 영어 Tesseract OCR과 라벨 기반 템플릿 파서로 동작합니다.

줄 링크는 참고용

각 값은 모델이 보고한 페이지와 줄로 연결됩니다. 줄 번호가 어긋날 수 있으므로 증거로 보지 않습니다(알려진 문제).

— CARGOCHECK AI · 검증

결정론적 규칙, 사람의 판단

두 서류가 확인되면 규칙이 확인된 값을 비교합니다. 규칙은 차이를 표시할 뿐이고, 그 의미는 검토자가 판단하고 이유를 기록합니다.

— 비교 항목

- 선적 참조번호, 판매자, 수하인, 주소
- 명시된 품목 코드, 모호한 매칭은 검토 대상으로 유지
- 호환되는 단위의 수량, 호환되지 않는 단위는 변환하지 않고 표시
- decimal.js로 줄 단위 계산: 수량 × 단가 = 기재된 줄 합계
- 순중량은 이번 버전에서 비교하지 않음으로 표시

표시 항목마다 판단

표시된 모든 검사에 판단이 기록되기 전에는 검토를 완료할 수 없습니다.

승인이 아님

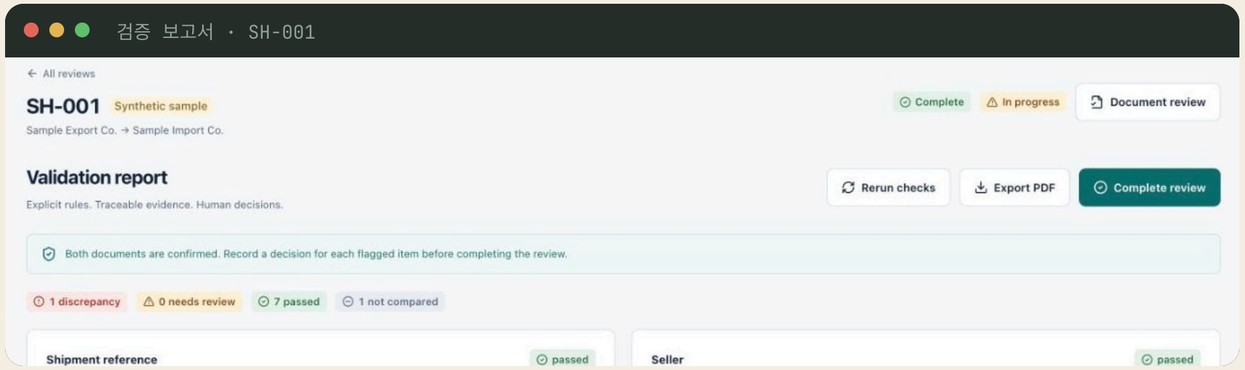
검토 완료는 검토자의 작업을 기록할 뿐이며, 선적을 승인하지 않습니다.

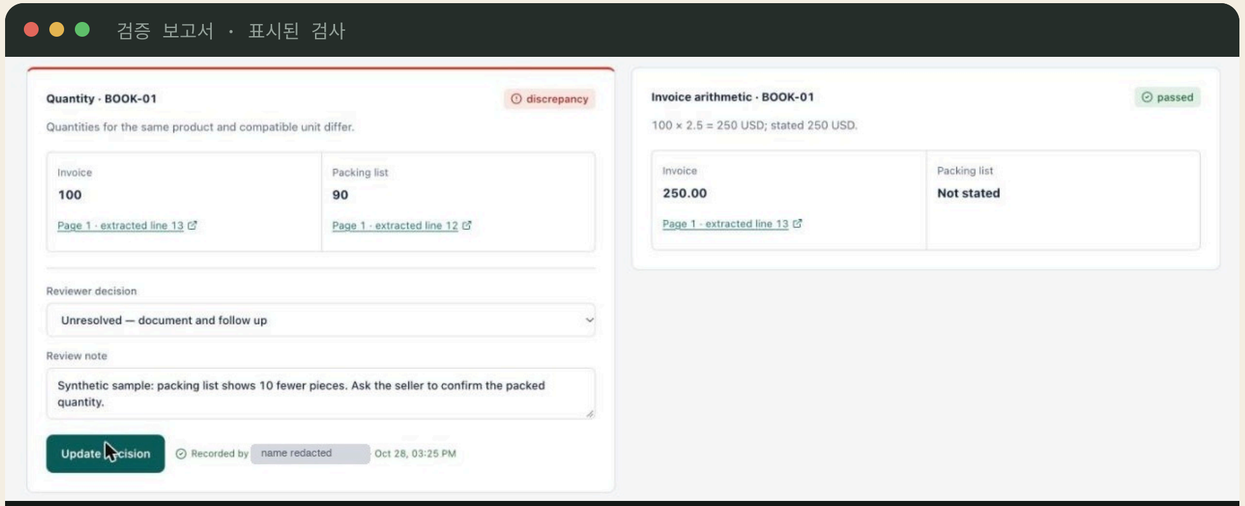
수정하면 검토가 다시 열립니다

원래 값은 보존되고 기존 판단은 해제되며, 이전 사본에서 한 수정은 409로 거부됩니다.

계정과 테스트

scrypt 비밀번호 해시, 해시 처리한 세션 토큰, 소유권·업로드 검사, CI 테스트 42/42 통과.





2026년 10월 28일 실제 화면: 송장 100개 대 포장 90개와 기록된 판단. 가상 값이며 검토자 이름은 가렸습니다.

— 주요 프로젝트 · 05 · 운영 중

Lexara.

운영 중인 공동 프로젝트이며 저는 개발에 참여했습니다. FastAPI 백엔드(API 엔드포인트, 업로드 처리, DB 모델, Alembic 마이그레이션)를 맡았습니다. 코드는 협업자의 GitHub 계정으로 반영했으며, 제 저장소는 MakhmudSD/Lexara의 포크입니다.

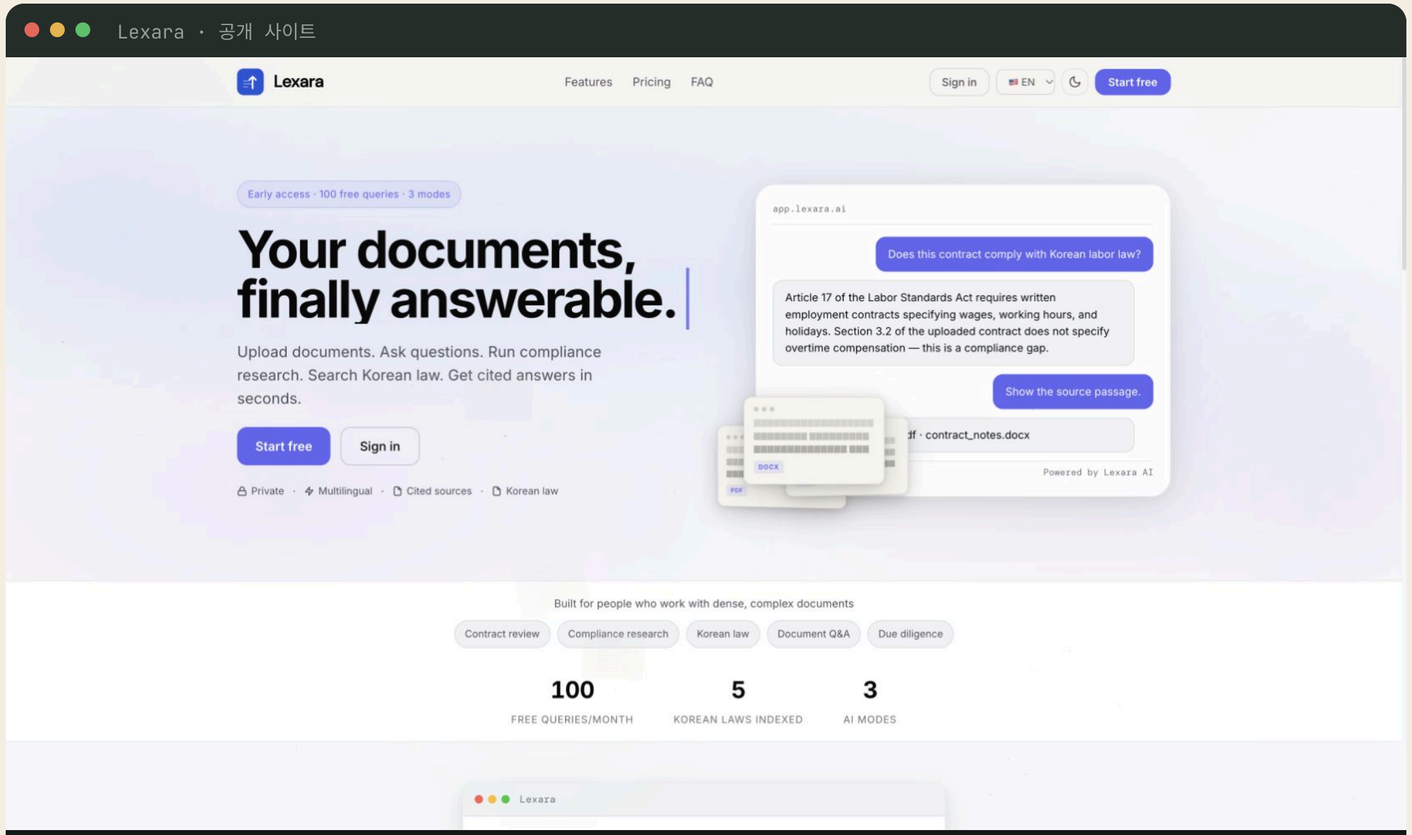
문서 질의응답 플랫폼입니다. 업로드한 문서를 작업 공간별로 관리하고, 답변에 근거가 된 문단을 출처로 표시합니다.

— 팀 아키텍처 · 제 담당: 백엔드

- FastAPI, PostgreSQL, SQLAlchemy, Alembic
- pgvector 유사도 검색과 BM25를 RRF로 결합
- 업로드는 202를 반환하고 백그라운드 작업으로 처리, 상태 폴링 제공
- React/Vite 프론트엔드, OpenAI 모델, 선택적 R2 스토리지

공개 사이트 ↗

저장소: kakhkhorov97/Lexara (MakhmudSD/Lexara의 포크)



공동 프로젝트 Lexara의 공개 랜딩 페이지 (2026년 10월 22일). 화면 속 예시 답변은 데모 콘텐츠입니다.

이전 README는 FAISS를 설명하지만, 확인한 현재 소스는 pgvector를 사용합니다. 로그인, 업로드, 채팅은 이 포트폴리오를 위해 테스트하지 않았습니다.

— 연락처

아이디어부터 운영까지

이메일	kakhkhorov97@gmail.com
전화	010-7901-7555
카카오톡	kakhkhorov_A
GITHUB	github.com/kakhkhorov97
포트폴리오	sean-kakhkhorov.site
CREATORHUB	creatorhub.site
SOFIYA	sofiya.store
KOREA VISA ASSISTANT	운영 중인 베타 열기 ↗
CARGOCHECK AI	실제 앱 열기 ↗
주소	대한민국 경기도 수원시



포트폴리오
sean-kakhkhorov.site

CreatorHub
creatorhub.site

Sofiya
sofiya.store